WILSON ANDRES SUAREZ MANTILLA – U00173315

🐕‍🦺 Clasificación de Razas de Perros - Stanford Dogs Dataset

Este proyecto implementa una red neuronal convolucional (CNN) diseñada para clasificar imágenes de perros en **120 categorías distintas** utilizando el dataset de Stanford.

📋 Resumen del Proceso

El flujo de trabajo se dividió en cinco etapas principales:

1. Configuración y Descarga

- **Librerías:** Uso de TensorFlow/Keras para el modelo, OpenCV para procesamiento de imágenes y Scikit-learn para la gestión de datos.
- **Dataset:** Descarga automatizada del *Stanford Dogs Dataset* (images.tar) y montaje de Google Drive para persistencia de datos.

2. Preprocesamiento Avanzado (Técnica de Boxing)

Para mejorar el enfoque del modelo, se implementó una función de **Boxing** personalizada utilizando OpenCV:

- **Detección:** Uso de algoritmos de Canny y detección de contornos para localizar al perro en la imagen.
- **Recorte (Cropping):** Extracción automática de la región de interés (el perro) descartando el fondo innecesario.
- **Normalización:** Redimensión de todas las imágenes a un tamaño estándar de **100x100 píxeles**.

3. Preparación de Datos

- **División (Split):** Los datos se segmentaron en un **80% para entrenamiento**, **10% para validación** y **10% para prueba**.
- **Generadores:** Uso de ImageDataGenerator para la carga eficiente de datos por lotes (batch size de 32).

4. Arquitectura del Modelo CNN Optimizado

Se diseñó una red secuencial con las siguientes características para mantener el conteo de parámetros bajo control:

- **Data Augmentation Integrada:** Capas de RandomFlip, RandomRotation y RandomZoom dentro del modelo.
- **Extracción de Características:** Dos bloques convolucionales con BatchNormalization, MaxPooling2D y Dropout (0.25).
- **Optimización de Parámetros:** Uso de GlobalAveragePooling2D en lugar de capas Flatten para reducir drásticamente el sobreajuste y la carga computacional.
- **Clasificador:** Capas densas de 256 y 128 neuronas con activación ReLU, finalizando en una capa Softmax de 120 salidas.

5. Entrenamiento y Callbacks

Se implementaron estrategias de control dinámico durante las 35 épocas de entrenamiento:

- **ReduceLROnPlateau:** Reducción del factor de aprendizaje si el accuracy de validación se estanca.
- **EarlyStopping:** Detención prematura tras 8 épocas sin mejoras para evitar el sobreajuste.
- **ModelCheckpoint:** Guardado automático del mejor peso obtenido.

📈 **Análisis de Resultados Finales**

Métrica	Valor Obtenido
Test Accuracy	~7.06%
Test Loss	~4.24
Referencia (Azar)	0.83%

Conclusión Técnica: El modelo logra superar la probabilidad del azar en más de un **6%**, demostrando aprendizaje. Sin embargo, la complejidad de 120 clases para una

CNN "pura" presenta un estancamiento evidente. Los resultados sugieren que, para este volumen de categorías, el camino a seguir es el **Transfer Learning**.